

UNIVERSIDAD DEL VALLE DE GUATEMALA

Visión por Computadora

Sección 11

Dr. Alan Gerardo Reyes



Excelencia que trasciende

DEL VALLE
GRUPO EDUCATIVO

Proyecto 1

Pablo Orellana	21970
Diego Leiva	21752
Maria Ramirez	21342
Gustavo Gonzalez	21438

Guatemala, 13 de marzo del 2025

Introducción

Este informe presenta el desarrollo y análisis de dos problemas relacionados con la representación y procesamiento de estructuras arteriales a partir de imágenes binarias. En el primer problema, se aborda la extracción de características geométricas, mientras que en el segundo problema se desarrolla una discretización de la estructura arterial en forma de grafo.

El objetivo es generar representaciones estructuradas que permitan analizar la morfología de la estructura y establecer comparaciones cuantitativas mediante métricas adecuadas.

Metodología

2.1 Problema 1: Identificación de Componentes en la Imagen

Para abordar este problema, se utilizó procesamiento de imágenes basado en operaciones morfológicas y técnicas de segmentación. La metodología se describe a continuación:

1. Carga y preprocesamiento de la imagen: Se lee la imagen groundtruth en escala de grises y se convierte a binario.
2. Extracción de regiones conectadas: Se aplicó el etiquetado de componentes conexos para segmentar las diferentes estructuras presentes en la imagen.
3. Identificación de componentes relevantes: Se eliminaron elementos irrelevantes mediante filtros basados en tamaño y forma.
4. Visualización de resultados: Se generaron imágenes resaltando las regiones identificadas y se evaluó su precisión en comparación con el groundtruth.

2.2 Problema 2: Discretización de la Estructura Arterial

El segundo problema consistió en convertir la estructura arterial en un grafo representado por nodos y aristas. A continuación, se describe el procedimiento detallado:

1. Se utilizó la operación de esqueletización (skeletonize) para reducir la estructura arterial a un solo píxel de grosor, preservando su conectividad.
2. Se recorrió la imagen binaria y se añadieron nodos en los píxeles del esqueleto. Luego se determinaron las conexiones entre píxeles vecinos para definir las aristas del grafo.

3. Se clasificaron los nodos según su grado de conectividad:
 - a. Nodos extremos: Conexión con un solo vecino.
 - b. Nodos intermedios: Conexión con exactamente dos vecinos.
 - c. Nodos de bifurcación: Conexión con tres vecinos.
 - d. Nodos de trifurcación: Conexión con más de tres vecinos.
4. Se utilizó un recorrido en profundidad (DFS) para eliminar nodos intermedios redundantes cada 3 pasos, reduciendo la complejidad del grafo sin perder información clave.
5. Se agruparon nodos de bifurcación y/o trifurcación cercanos en una única representación para simplificar la estructura, dejando el nodo más representativo y eliminando el resto de los nodos redundantes.
6. Se generó una imagen superponiendo el grafo sobre la imagen original con colores diferenciados para cada tipo de nodo.
7. Se guardó la estructura del grafo en un archivo JSON, incluyendo nodos, conexiones y clasificaciones.

Resultados y Discusión

3.1 Problema 1

Se presentan a continuación los resultados de las métricas extraídas:

Image	Accuracy	Sensitivity/Recall	Specificity	Precision	F1 Score
1.pgm	0.129189	0.158815	0.12783	0.00828499	0.0157484
10_gt.pgm	0.163367	0.122098	0.165117	0.00616297	0.0117337
11_gt.pgm	0.161244	0.108635	0.165774	0.0110866	0.0201199
12_gt.pgm	0.163656	0.0586592	0.168005	0.00291218	0.00554888
13_gt.pgm	0.162778	0.188954	0.160758	0.0170732	0.0313167
14_gt.pgm	0.1211	0.0645234	0.12402	0.00378717	0.00715442
15_gt.pgm	0.208478	0.0737985	0.216355	0.00547778	0.0101986
16_gt.pgm	0.1073	0.141463	0.105584	0.00788288	0.0149336
17_gt.pgm	0.160978	0.156479	0.161223	0.0100525	0.0188915
18_gt.pgm	0.163733	0.147686	0.164513	0.00851711	0.0161054
19_gt.pgm	0.150711	0.111346	0.152437	0.00572812	0.0108957
2.pgm	0.128956	0.0804886	0.132657	0.00703763	0.0129435
20_gt.pgm	0.140156	0.0524953	0.144498	0.00303055	0.00573029
3.pgm	0.143978	0.0685077	0.147274	0.00349631	0.00665309
4.pgm	0.134022	0.33392	0.124781	0.017333	0.0329553
5.pgm	0.154289	0.109985	0.155951	0.00486578	0.00931928
6.pgm	0.153022	0.0588056	0.156588	0.00263187	0.00503824
7.pgm	0.158889	0.0963883	0.162125	0.00592036	0.0111555
8.pgm	0.154756	0.238866	0.150639	0.0135763	0.0256923
9.pgm	0.177267	0.0597862	0.18357	0.00391367	0.00734644
nan	0.151893	0.121585	0.153485	0.00743855	0.013974

Tabla 1: Métricas de Resultados para Binarización Adaptativa

Image	Accuracy	Sensitivity/Recall	Specificity	Precision	F1 Score
1.pgm	0.0765556	1	0.0341886	0.0453491	0.0867635
10_gt.pgm	0.153733	0.367659	0.144662	0.0179001	0.0341382
11_gt.pgm	0.0822222	0.941688	0.00823015	0.0755664	0.139906
12_gt.pgm	0.139778	0.0756983	0.142432	0.00364335	0.0069521
13_gt.pgm	0.125156	0.370307	0.106243	0.0309743	0.0571668
14_gt.pgm	0.0380667	0.419742	0.0183681	0.021592	0.0410713
15_gt.pgm	0.184067	0.270259	0.179025	0.0188899	0.0353117
16_gt.pgm	0.0836222	0.188153	0.078371	0.0101518	0.0192642
17_gt.pgm	0.128367	0.187688	0.125138	0.0115428	0.0217481
18_gt.pgm	0.0259333	0.280508	0.0135618	0.0136308	0.0259983
19_gt.pgm	0.114867	0.275853	0.107807	0.0133775	0.0255174
2.pgm	0.107311	0.115722	0.106669	0.00979664	0.018064
20_gt.pgm	0.107233	0.354284	0.0949949	0.0190239	0.0361089
3.pgm	0.108856	0.351567	0.0982559	0.0167415	0.031961
4.pgm	0.0685333	0.612773	0.0433721	0.0287623	0.0549456
5.pgm	0.0766889	0.543164	0.059185	0.0212044	0.0408154
6.pgm	0.0769222	0.623096	0.0562513	0.0243786	0.0469214
7.pgm	0.0908333	0.12167	0.0892369	0.0068686	0.0130031
8.pgm	0.124022	0.261967	0.117271	0.0143156	0.0271478
9.pgm	0.149422	0.0864063	0.152803	0.00544248	0.01024
nan	0.103109	0.37241	0.0888033	0.0204576	0.0386522

Tabla 2: Métricas de Resultados para Binarización Combinada

Métrica	Binarización Adaptativa	Binarización Combinada
Accuracy	0.151893	0.103109
Sensitivity/Recall	0.121585	0.37241
Specificity	0.153485	0.0888033
Precision	0.00743855	0.0204576
F1 Score	0.013974	0.0386522

Tabla 3: Comparación de Métricas de Resultados para Binarización Combinada y Adaptativa

- La binarización adaptativa tiene una precisión promedio de 0.1519, mientras que la combinada tiene un promedio de 0.1031. Con esto podemos deducir que el método adaptativo ofrece una clasificación más precisa en general.
- La binarización combinada muestra un recall mayor, con un valor promedio de 0.3724, en comparación con la adaptativa, con un valor de 0.1215. Esto nos indica que la binarización combinada es más efectiva para detectar los píxeles de la clase positiva, lo que puede ser útil en aplicaciones donde es fundamental no omitir información importante.
- La binarización adaptativa tiene una especificidad de 0.1534, mientras que la combinada tiene 0.0888. Esto indica que el método adaptativo es más preciso en la identificación de los píxeles negativos.
- La precisión y el F1 Score son mayores en la binarización adaptativa en comparación con la combinada. Esto sigue favoreciendo al método adaptativo en términos de un balance entre detección y exactitud.

Al analizar los resultados de la binarización en el Problema 1, se observó que las imágenes procesadas no están bien definidas en algunos casos. En ciertas binarizaciones, se perdió parte de la estructura de las arterias y se generó una gran cantidad de ruido. Aunque en la mayoría de los casos se logró visualizar la estructura de las arterias, el ruido circundante (como manchas) afectó la calidad de la segmentación.

Resultados de la imagen: 2 (Imagen 12)




Figura 1: Visualización de la binarización de imágenes

La tabla de resultados muestra que la precisión general de la segmentación es baja. Las métricas de sensibilidad son relativamente altas en algunas imágenes, lo que indica que se identificaron muchas arterias, pero la especificidad es baja, lo que sugiere una gran

cantidad de falsos positivos. Esto implica que el ruido en la imagen está afectando la segmentación.

Para mejorar los resultados, se sugiere la aplicación de operaciones morfológicas como white top-hat, erosión y dilatación, que pueden ayudar a reducir el ruido y mejorar la segmentación de las arterias. Además, el uso de técnicas de aprendizaje automático podría ayudar a optimizar el proceso de binarización y mejorar la detección de estructuras en la imagen.

3.2 Problema 2

Para este problema los resultados son los siguientes:




Figura 2: Esqueletización de las imágenes groundtruth de una estructura arterial




Figura 3: Visualización de la discretización de las imágenes




Figura 4: Comparación de la Estructura Arterial original, su Groundtruth y su representación discretizada.

El algoritmo cumple con los objetivos planteados, logrando una discretización efectiva de las estructuras arteriales. Sin embargo, se identificaron algunos aspectos a considerar:

- La precisión en la identificación, ya que la clasificación de nodos intermedios depende de los parámetros del algoritmo de reducción, lo que podría generar pequeñas variaciones en la estructura final.
- Algunas imágenes de groundtruth contienen bastantes imperfecciones, por lo que el proceso de esqueletización podría introducir artefactos que afecten la estructura del grafo.
- Se podría requerir de una nueva configuración de parámetros según el dataset y con qué tanto ruido se encuentren las imágenes a utilizar.

Conclusiones

- La binarización identificó arterias en la mayoría de las imágenes, pero introdujo ruido y pérdidas de estructura en algunas.
- Se recomienda utilizar técnicas morfológicas y explorar el uso de aprendizaje automático para mejorar la precisión y reducir el ruido.
- El algoritmo de discretización generó un grafo adecuado, pero dependió de los parámetros de reducción, causando variaciones.
- Los algoritmos fueron efectivos, pero enfrentaron desafíos debido al ruido y las imperfecciones en los datos.

Referencias

Berman, E. (2024, 16 noviembre). Depth-First Search (DFS) Algorithm - Eli Berman -

Medium. *Medium*. <https://medium.com/@that-software-PM/depth-first-search-dfs-algorithm-201dc95e524>

Sauvola, J., & Pietikäinen, M. (2000). Adaptive document image binarization. *Pattern Recognition*, 33(2), 225-236. [https://doi.org/10.1016/s0031-3203\(99\)00055-2](https://doi.org/10.1016/s0031-3203(99)00055-2)

Skeletonize — *skimage 0.25.2 documentation*. (s. f.). https://scikit-image.org/docs/stable/auto_examples/edges/plot_skeleton.html

Tutorial — *NetworkX 3.4.2 documentation*. (s. f.). <https://networkx.org/documentation/stable/tutorial.html>